

UNIDAD 2

ACTIVIDAD PRÁCTICA

PROYECTO: ANÁLISIS DE SENTIMIENTO Y TENDENCIAS EN REDES SOCIALES - EXTRACCIÓN Y TRATAMIENTO DE DATOS

ÍNDICE

ORGANIZACIÓN DE LA ACTIVIDAD PRÁCTICA.....	3
DESCRIPCIÓN DE LA ACTIVIDAD PRÁCTICA	3
RECOMENDACIONES E INDICACIONES PARA LA ENTREGA.....	5
RÚBRICA DE CORRECCIÓN	6
COMO REALIZAR LA ENTREGA.....	7

ORGANIZACIÓN DE LA ACTIVIDAD PRÁCTICA

Proyecto: análisis de sentimiento y tendencias en redes sociales - Extracción y tratamiento de datos	
Tipo de tarea	Individual
Entregables	Repositorio de Github, Google Colab o documento comprimido

DESCRIPCIÓN DE LA ACTIVIDAD PRÁCTICA

En esta entrega parcial, se deberá implementar la fase inicial del proyecto, la cual abarca la extracción de datos textuales, el almacenamiento, la limpieza y normalización del texto, y un análisis básico del contenido. Específicamente, se utilizará un dataset predefinido de tweets.

Requisitos de la actividad:

- Extracción de Datos Textuales:
 - Utilizar un dataset predefinido que contenga tweets relacionados con un tema específico. Como punto de partida, se puede utilizar el siguiente que contiene datos sobre Bitcoin: [https://www.kaggle.com/datasets/kaushiksuresh147/bitcoin-tweets/data?select=Bitcoin tweets dataset 2.csv](https://www.kaggle.com/datasets/kaushiksuresh147/bitcoin-tweets/data?select=Bitcoin+tweets+dataset+2.csv)
- Almacenamiento de Datos:
 - Guardar los datos extraídos en un formato estructurado (CSV o JSON) asegurando la correcta codificación (UTF-8).
- Limpieza y Normalización:
 - Aplicar expresiones regulares para eliminar URLs, menciones, caracteres especiales y emojis innecesarios.
 - Normalizar el texto (conversión a minúsculas, eliminación de espacios redundantes).
- Análisis Básico:
 - Extraer hashtags y palabras clave de los tweets.
 - Generar visualizaciones (por ejemplo, wordclouds) que muestren las palabras más frecuentes.
- (Opcional/Bonus):
 - Desarrollar un mini-dashboard utilizando Streamlit para visualizar los resultados interactivos.

Se deberá centralizar todos los pasos en la siguiente clase de Python que se tendrá que completar. Se podrá hacer uso de otras funciones, clases, métodos, etc., siempre y cuando se acabe centralizando todo en esta clase:

Class DataExtractor:

```
def __init__(self, source_file: str, chunksize: int = 100000):
```

```
"""
```

Inicializa el extractor con el archivo de origen.

Parámetro:

source_file: Ruta al archivo de datos (CSV o JSON).

```
"""
```

```
self.source_file = source_file
```

```
self.data = None
```

```
self.chunksize = chunksize
```

```
def load_data(self):
```

```
"""
```

Carga los datos del archivo de origen.

Implementación esperada:

- Leer el archivo en el formato correspondiente (CSV o JSON).
- Almacenar los datos en self.data.

```
"""
```

```
return self.data
```

```
def clean_text(self, text: str) -> str:
```

```
"""
```

Limpia y normaliza el texto.

Pasos sugeridos:

- Convertir a minúsculas.
- Eliminar o extraer URLs.
- Eliminar caracteres especiales (OJO! necesitamos hashtags) y espacios redundantes.

Devuelve:

El texto limpio.

```
"""
```

```
return text
```

```
def extract_hashtags(self, text: str) -> list:
```

```
"""
```

Extrae y devuelve una lista de hashtags presentes en el texto.

Implementación sugerida:

- Utilizar expresiones regulares para encontrar palabras que comiencen con '#' .

```
"""
```

```
return hashtags
```

```
def analytics_hashtags_extended(self) -> dict:
```

```
"""
```

Realiza un análisis avanzado de hashtags sobre el conjunto de datos cargado (self.data).

El método realiza los siguientes pasos:

1. Aplica la función clean_text a la columna 'text' para normalizar los datos.
2. Extrae los hashtags de cada texto usando extract_hashtags y los almacena en una nueva columna.
3. Convierte la columna 'date' a tipo datetime y extrae solo la fecha (sin la hora).
4. Explota la columna de hashtags para obtener una fila por cada hashtag, lo que facilita los cálculos de frecuencia.

5. Calcula tres análisis:

- Frecuencia total de cada hashtag (overall).
- Frecuencia de hashtags por usuario (by_user).
- Evolución de la frecuencia de hashtags por día (by_date).

Retorna:

Un diccionario con tres DataFrames, con claves:

'overall': DataFrame con columnas ['hashtag', 'frequency'].

'by_user': DataFrame con columnas ['user_name', 'hashtag', 'frequency'].

'by_date': DataFrame con columnas ['date', 'hashtag', 'frequency'].

"""

return {'overall': overall, 'by_user': by_user, 'by_date': by_date}

def generate_hashtag_wordcloud(self, overall_df: pd.DataFrame = None, max_words: int = 100, figsize: tuple = (10, 6)) -> None:

"""

Genera y muestra una wordcloud basada en el análisis global de hashtags.

Este método utiliza el DataFrame 'overall' que contiene la frecuencia global de cada hashtag. Si no se proporciona el DataFrame, se calcula llamando a analytics_hashtags_extended().

Parámetros:

overall_df (pd.DataFrame, opcional): DataFrame con columnas ['hashtags', 'frequency']. Si es None, se calcula.

max_words (int, opcional): Número máximo de palabras a incluir en la wordcloud.

figsize (tuple, opcional): Tamaño de la figura a mostrar.

Proceso:

1. Si overall_df es None, llamar a analytics_hashtags_extended y extraer la parte 'overall'.
2. Convertir el DataFrame a un diccionario donde las claves sean los hashtags y los valores sean las frecuencias.
3. Utilizar la clase WordCloud de la librería wordcloud para generar la nube de palabras.
4. Visualizar la wordcloud con matplotlib.

RECOMENDACIONES E INDICACIONES PARA LA ENTREGA

Se recomienda:

- Utilizar notebooks, sea en VSCode, Jupyter o PyCharm o Google Colab
- Utilizar el dataset llamado "Bitcoin_tweets_dataset_2.csv" para evitar problemas de cómputo debido al tamaño del dataset
- Guardar todo en un repositorio de Github para usar como base en futuras entregas
- Hacer un análisis básico sobre el número de ocurrencias de los hashtags y cómo evoluciona en el tiempo
- Debes plantearte: ¿y si todas las ocurrencias son de un número de perfiles? ¿serán bots?
- Genera un archivo de markdown o txt para la documentación

- Recuerda, para archivos de gran tamaño es útil utilizar “chunksize” en Pandas y desactivar el modo “low_memory”
- Para procesar bien un csv, es útil identificar cuál es el carácter que se utiliza como fin de línea, depende de la procedencia puede ser diferente.

RÚBRICA DE CORRECCIÓN

Criterios	Excelente	Satisfactorio	No satisfactorio	Insuficiente
Criterio 1: Extracción de Datos	De 1.6 a 2 puntos -Conexión (o lectura) correcta y extracción completa de los tweets; documentación detallada y clara del origen y proceso.	De 1.1 a 1.5 puntos - Extracción funcional de la mayoría de los tweets; documentación aceptable pero con detalles limitados.	De 0.6 a 1 puntos -Extracción parcial o con errores significativos; documentación poco clara o incompleta.	De 0 a 0.5 puntos -No se logra extraer los datos o se extraen datos irrelevantes; falta total de documentación.
Criterio 2: Almacenamiento de Datos	De 1.6 a 2 puntos - Almacenamiento correcto en el formato elegido (CSV o JSON).- Justificación clara y adecuada de la elección del formato.- Integridad y correcta codificación de los datos.	De 1.1 a 1.5 puntos - Almacenamiento en el formato correcto.- Justificación limitada de la elección.- Integridad de datos mayoritariamente correcta.	De 0.6 a 1 puntos - Almacenamiento incompleto o con errores.- Justificación poco clara o ausente.- Problemas con la codificación de los datos.	De 0 a 0.5 puntos - No logra almacenar los datos correctamente.- Formato incorrecto.- Fallos graves en la codificación.
Criterio 3: Limpieza y Normalización	De 1.6 a 2 puntos - Aplicación completa y efectiva de expresiones regulares para limpiar y normalizar el texto.- El texto limpio muestra una mejora significativa.- Manejo adecuado de la	De 1.1 a 1.5 puntos - Aplicación funcional de limpieza y normalización, aunque con posibles optimizaciones.- El texto limpio es mayormente correcto.- Manejo correcto de la codificación.	De 0.6 a 1 puntos - Limpieza y normalización incompleta o con errores.- El texto limpio presenta aún elementos no deseados.- Problemas con la codificación de caracteres.	De 0 a 0.5 puntos - No logra limpiar ni normalizar el texto.- El texto contiene numerosos errores y elementos no deseados.- Fallos graves en la codificación.

	codificación (UTF-8).			
Criterio 4: Análisis Básico	De 1.6 a 2 puntos - Extracción y ranking de hashtags y palabras clave realizada de manera completa y precisa.- Wordclouds generadas con personalización adecuada y relevancia.	De 1.1 a 1.5 puntos - Extracción y ranking mayoritariamente correcta.- Wordclouds generadas correctamente, aunque con pocas personalizaciones.	De 0.6 a 1 puntos - Extracción de hashtags o palabras clave incompleta.- Wordclouds generadas de manera limitada o con errores.	De 0 a 0.5 puntos - No logra extraer hashtags ni generar wordclouds.- Visualizaciones incorrectas o inexistentes.
Criterio 5: Presentación y Documentación	De 1.6 a 2 puntos - Presentación clara y profesional de los resultados.- Documentación completa y detallada que facilita la reproducibilidad.- Inclusión de visualizaciones efectivas y relevantes.	De 1.1 a 1.5 puntos - Presentación adecuada de los resultados, aunque podría ser más clara.- Documentación suficiente para entender el proceso.- Visualizaciones correctas pero limitadas.	De 0.6 a 1 puntos - Presentación de resultados confusa o incompleta.- Documentación insuficiente o poco clara.- Visualizaciones presentes pero poco efectivas.	De 0 a 0.5 puntos - Presentación desorganizada o inexistente.- Falta total de documentación.- No incluye visualizaciones o son irrelevantes.

COMO REALIZAR LA ENTREGA

A modo de guión o proceso sobre cómo realizar la entrega, se recomienda seguir el siguiente proceso:

- Subir a GitHub/ Google Colab/ Zip: asegúrate de subir el código, archivos de datos y documentación a un repositorio en GitHub, un archivo comprimido o un enlace de Google Colab compartido.
- Documentación: incluye un archivo README.md que explique:
 - La fuente de datos utilizada.
 - La metodología de extracción, limpieza y análisis.
 - Instrucciones claras para ejecutar el notebook o scripts.
- Visualizaciones: inserta capturas de pantalla de las visualizaciones generadas (por ejemplo, wordclouds) y diagramas que expliquen el flujo de datos.
- Entregables: debes incluir todos los entregables especificados con especial enfoque en la clase de Python proporcionada completando los métodos. Puedes crear otras funciones, clases, métodos, etc., auxiliares para ayudarte, pero deben ser independientes a la clase DataExtractor.